


Machine Learning – Regularización

Underfitting

Overfitting



Definición

Proceso que altera ligeramente la formulación matemática de un modelo, con la intención de **prevenir el overfitting**. Una manera de regularizar puede ser eliminando grados de una regresión polinómica o aplanando los pesos (w).

De esta manera simplificamos los modelos para que haya menos overfitting y generalicen mejor. A cambio sufriremos un pequeño aumento en los errores. De nuevo, Bias vs Variance.

Se suele aplicar en regresiones lineales y logísticas, pero también existen en otros modelos. Las penalizaciones más populares son:

1. **L2**: consigue que los parámetros estimados por el modelo (w) no tengan (en valor absoluto) un valor demasiado grande, de manera que aplanan los pesos y evita los extremos.
2. **L1**: tiende a eliminar los pesos con menor importancia, es como si estuviese realizando un feature selection.

Regresiones que utilizan regularización:

3. **Ridge**: utiliza L2
4. **Lasso**: utiliza L1
5. **Elastic Net**: combinación lineal de L1 y L2

Ridge

Añade este nuevo término a la función de costes

$$\lambda \sum_{j=0}^p w_j^2$$

De tal manera que:




$$\sum_{i=1}^M (y_i - \hat{y}_i)^2 = \sum_{i=1}^M \left(y_i - \sum_{j=0}^p w_j \times x_{ij} \right)^2 + \lambda \sum_{j=0}^p w_j^2$$

Cuanto mayor es Alpha, más estoy regularizando el modelo y la generalización debería ser mejor.

Por otro lado, el modelo final contará con todos los predictores

 **El hiperparámetro alpha** controla cuánto regularizamos el modelo. Si alpha es 0, sería una regresión lineal normal. Sin embargo, si alpha es muy grande todos los pesos serían cercanos a 0 y el resultado de la regresión equivaldría a una línea plana.

Ridge



Lasso



Least Absolute Shrinkage and Selection Operator Regression (Lasso). Añade un término de regularización a la función de costes, que en este caso es la norma l1 del vector de pesos

$$\sum_{i=1}^M (y_i - \hat{y}_i)^2 = \sum_{i=1}^M \left(y_i - \sum_{j=0}^p w_j \times x_{ij} \right)^2 + \lambda \sum_{j=0}^p |w_j|$$



La regresión de Lasso elimina los pesos de las variables menos importantes, como en la siguiente imagen donde pone a 0 los pesos de los grados altos de la regresión polinómica. **Es una forma de hacer feature selection.**

En presencia de correlaciones entre las variables Lasso puede tener comportamientos inestables



Elastic Net

Término medio entre la regresión de Ridge y la de Lasso. El término de regularización es una mezcla entre ambos:

$$J(\theta) = \text{MSE}(\theta) + r\alpha \sum_{i=1}^n |\theta_i| + \frac{1-r}{2}\alpha \sum_{i=1}^n \theta_i^2$$

¿**Cuándo usamos Ridge, Lasso o Elastic Net?** En toda regresión siempre se recomienda algo de regularización para que no se produzca overfitting, y por tanto el modelo generalice mejor.

Por defecto Ridge funciona bastante bien aunque si sospechas que solo unas pocas features serán las buenas, quizá te encaje mejor Lasso o Elastic Net, ya que van a reducir o eliminar esas features.

Igualmente te encajarían estos dos últimos si tienes muchas features y quieres que la regularización realice una selección.

Elastic Net y Lasso funciona muy bien cuando tenemos muchas features.

Estandarización

Se recomienda utilizar el StandardScaler de sklearn, ya que los modelos que utilizan gradient descent son sensibles a las escalas de las variables.

Bibliografía

<https://learning.oreilly.com/library/view/hands-on-machine-learning/9781492032632/>

<https://www.cienciadedatos.net/documentos/py14-ridge-lasso-elastic-net-python.html>

<https://towardsdatascience.com/regularization-in-machine-learning-76441ddcf99a>

<https://towardsdatascience.com/ridge-lasso-and-elasticnet-regression-b1f9c00ea3a3>